



A Semi-supervised Graph Attentive Network for Financial Fraud Detection

Introduction



[배경 설명]

- Fintech 서비스는 많은 사람들에게 편리를 주고 있고, 이 분야는 최근 많은 성장을 하고 있다. → 핀테크의 성장에 따라 fraud도 증가하고 있다.
- 여러 종류의 Fraud는 유저와 회사의 security에 타격을 준다. 그러므로, Fraud Detection 방법의 탐구는 중요하다.

[태스크 정의]

- Fraud Detection은 엔터티(유저, 디바이스 등)가 미래에 Fraud activity를 수행할 지 여부를 예측하는 task.

[기존 방법의 한계]

- 일반적으로, 전통적인 접근에서, 이 Fraud Detection은 규칙 기반으로 수행되는 이진 분류 작업으로 간주되었다.
 - 규칙-기반의 Fraud Detection은 오랫동안 산업에서 사용되었지만, 이 방법에 대한 결점들이 있다.
 1. 이것은 너무 인간의 사전 지식(expert knowledge)에 의존한다.
 2. 그래서, 이 방법은 복잡한 패턴과 변화를 다루기 어렵다.
 3. 규칙 기반 방법은 공격 당하기 쉽다. (공격자가 한번 FD 시스템의 규칙을 알고 나면, 그 시스템은 공격 당하기 쉬워진다.)

Introduction



[대안1 제시]

- 규칙-기반 FD 방법이 가진 한계를 극복하기 위해, 자동으로 fraud pattern을 찾기 위한 ML 방법이 제안되었다.
 - 대부분의 ML은 유저의 다양한 측면(프로필, 행동, 트랜잭션 요약정보)에서 유저의 통계적 특징을 추출한다.

[대안1 한계]

- 전통적인 ML 방법은 분류 작업을 수행하기 위해 로지스틱 회귀, NN 등에 기반하여 예측을 수행한다.
- 하지만, 이 방법은 유저 간 **interaction**을 거의 고려하지 않는다.
 - 사용자들은 다양한 사회적 관계를 갖는다. 이들은 다른 사용자와 트랜잭션을 주고 받는다.
 - 이런 관계에 대한 정보는 이상 거래를 탐지하는 데 도움이 될 수 있다.

[대안1 한계 극복 시도: Graph Embedding]

- Conventional approaches: 일부 연구자는 유저 상호관계를 통합하기 위해 그래프 임베딩 사용.
- 하지만 FD에서 labeled 데이터는 별로 없고, 우리가 가진 건 (기존의 그래프 기반 방법에서는 이용되지 않은) 다수의 unlabeled 데이터일 뿐.

Introduction



[대안2: author's proposal]

- 기존 방법의 한계를 극복하기 위해, labeled and unlabeled multi-view data both를 이용하여 FD 수행할 것

[semiGNN]

- The basic idea of SemiGNN is to enhance the representations of users by fully exploiting the relational data and attribute data of both labeled and unlabeled data.
- [Advantages]
 1. Using Labeled, unlabeled information
 2. 우리 모델은 comprehensive result를 얻기 위해 multiview data를 통합시킨다.
 3. Attribution을 Dense feature로 이용하지 않고, attribute network를 구축하는 것은 attribute information의 representation을 향상시킴.
 4. 우리는 계층적 어텐션 메커니즘을 모델 내에 넣었다.
 1. 어텐션은 data의 다양한 관점 간의 상관관계를 구하도록 함.
 2. 어텐션 기반 모델은 해석 가능한 결과를 제공하기 때문에 task에 대한 인사이트를 제공할 수 있음.

[Considerations]

- 어떻게 labeled & unlabeled 둘다 사용할 것인가
 - 적은 수의 유저만이 fraud or not 여부가 라벨되어 있을 뿐
 - 어떻게 data heterogeneity를 모델링 할 것인가
 - multiview data를 이용하는 건 더 포괄적인 정보를 제공할 수 있다. 그런데, 사회적 관계 & 유저 특성 같은 multiview data는 different 통계적 속성을 지닌다.
 - 그런 이질성은 다측면적 데이터를 통합하는 데 어려움을 준다.
- 어떻게 해석 가능한 모델을 학습시킬 것인가
 - 금융 서비스 제공자는 (이상 거래 탐지에 대한) 예측 결과에 대한 지식을 better 얻게 해주는 해석 가능한 모델을 원한다.

Related Work



A. Financial Fraud Detection

- Credit card fraud, Insurance fraud 등이 연구되어 왔다.
- 초창기 연구는 fraud activities에는 어떤 패턴이 있다는 가정 하에 규칙-기반 방법을 사용했다.
 - 이 방법은 단순함과 해석의 용이성 때문에 인기있게 사용되었다.
 - 그러나 이 규칙 기반 방법은 인간이 사전에 갖고 있는 지식에 너무 의존적이었다.
 - 이들은 변화하는 복잡한 패턴을 포착하기에 어려움이 있었다.
 - 게다가, 한번 fruad attacker에게 규칙이 발각되면, attacker는 공격을 더 쉽게 할 수 있었다.


B. Learning over graphs

- Network Embedding
 - 그래프의 구조를 모델링할 수 있는 효과적인 방법
 - 각 노드에 대한 low-dimensional vector-representation 학습이 목적
- Graph Convolution Network
 - Network topology와 Node attribute를 동시에 학습할 수 있는 귀납적 방법
 - 이것은 보통 link prediction을 위해 고안되기 때문에 classification 성능에는 suboptimal
 - 이것은 interpretable results 제공 x

The model

Data 특징

- Different views 가 있고, each view는 different information 표현



SemiGNN 특징

- 이 모델은 다양한 유형의 nodes와 그래프의 다양한 views를 다룰 수 있다.
- 계층적 어텐션 구조
 - From node-level to view-level
- 이 모델은 각 view에서 rich semantic을 fuse할 수 있고, comprehensive user embedding을 학습할 수 있다.
- 이 모델은 어텐션을 이용한 덕택에 해석에 용이할 수 있다.
 - 어떤 node가 주어진 task에서 중요한지, 어떤 factor가 어느 유저가 fraud or not 여부를 분류하는 데 중요한지 알 수 있음

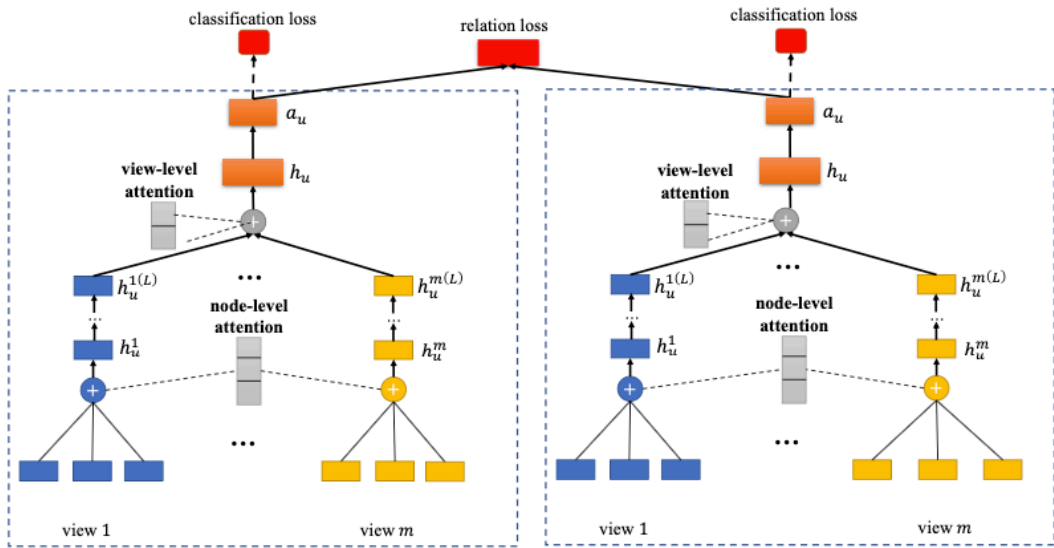
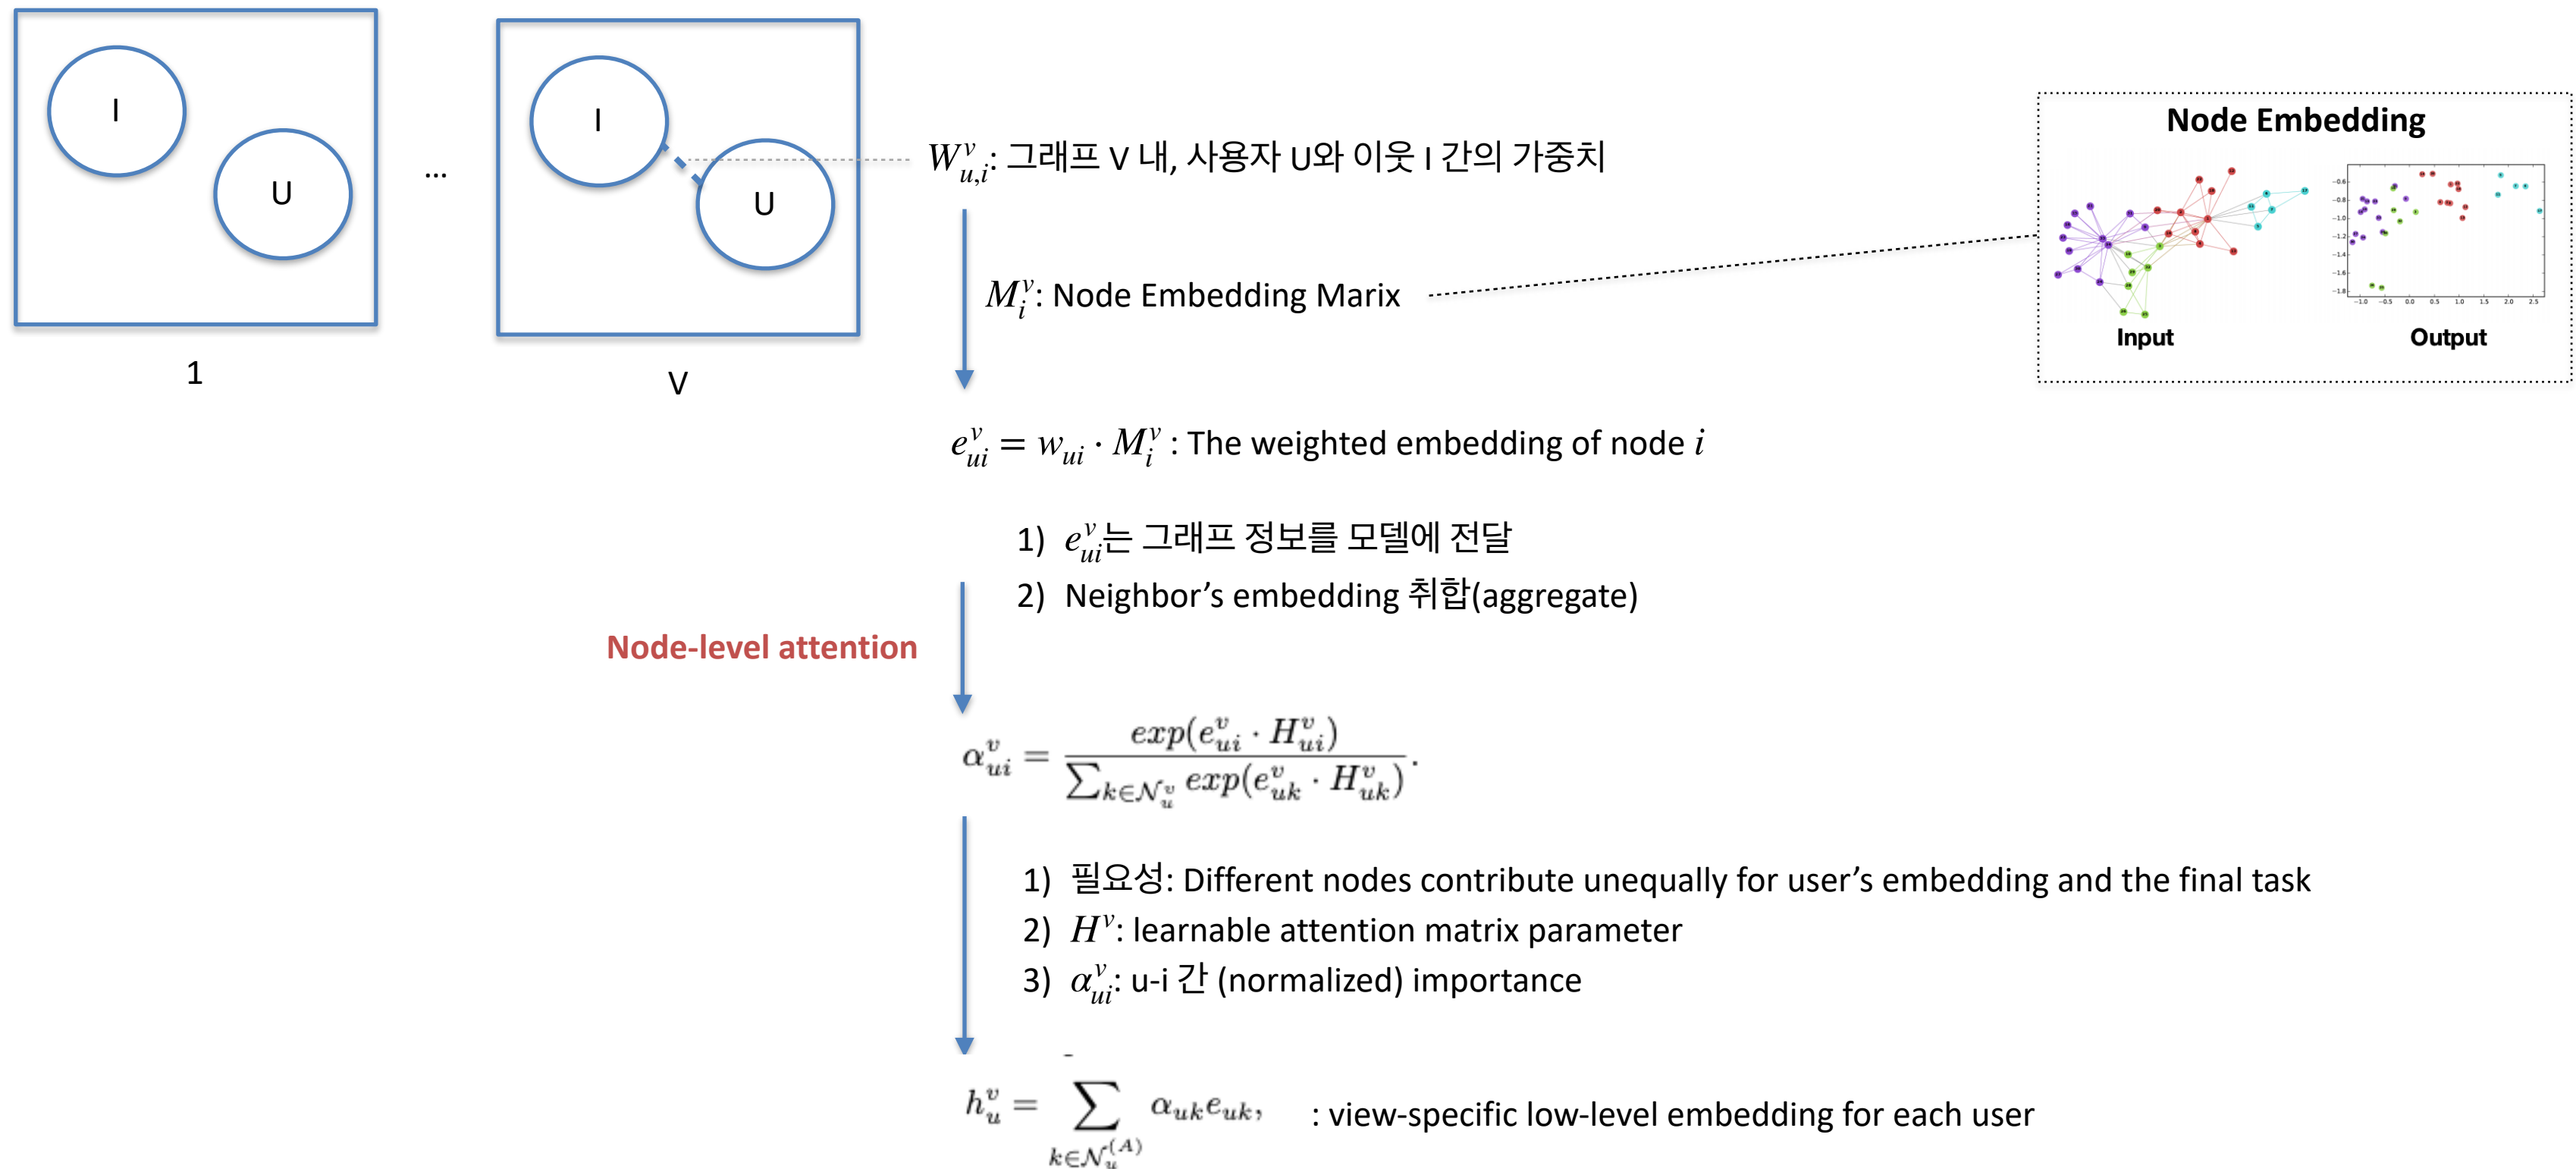


Fig. 2. The framework of the proposed model SemiGNN.

The model

Node-level Attention



The model

View-level Attention

To fuse multiple views of information

- 1) 각 view에 대한 user embedding (h_u^v)을 comprehensively 학습하기 위해 요구됨
- 2) **Problem:** low-level representations of multiview data lie in heterogeneous domains, which makes it difficult to capture the multiview correlations in low-level space
- 3) **Solution:**
 - 1) Use separate MLP to project **low-level view-specific user embedding** → **high-level semantic space**.
 - 1) It is easier to correlate multiview data
 - 2) Integrate multiview data
 - 1) We propose a view-level attention mechanism to automatically learn the importance of different views and accordingly integrate multiview data

$$h_u^{v(l)} = \text{Relu}(h_u^{v(l-1)}W_l^v + b_l^v), v \in \{2, \dots, m\},$$

where $h_u^{v(1)} = h_u^v$.

view-level attention

The view-level attention mechanism models **personalized** preference on different views

$$\alpha_u^v = \frac{\exp(h_u^{v(L)} \cdot \phi_u^v)}{\sum_{k \in \{1, \dots, m\}} \exp(h_u^{k(L)} \cdot \phi_u^k)}, v \in \{1, \dots, m\},$$

ϕ_u^v : view preference vector

- for user to guide the view - level attention mechanism.
- It is randomly initialized

Concatenate

$$h_u = ||_{i=1}^m (\alpha_u^v \cdot h_u^{v(L)}),$$

a_u : Use a one-layer perceptron, which use h_u as the input to refine the representations

The model Loss

For labeled users,

Use softmax on the representations of the embedding layer to get the classification result

$$\mathcal{L}_{sup} = -\frac{1}{|U_L|} \sum_{u \in U_L} \sum_{i=1}^k I(y_u = i) \log \frac{\exp(a_u \cdot \theta_i)}{\sum_{j=1}^k \exp(a_u \cdot \theta_j)},$$

- $I(\cdot)$ is the indicator function
- k is the number of occupations to be predicted
- θ is the parameter of the softmax.


For **un**labeled users,

- 하지만 다수의 사용자는 fraud or not 에 대해 unlabeled 되어 있음.
- 이들 모두를 label하는 것은 resource - consuming
- Unlabeled data도 이용하여 model training을 해보자.
 - How? Labeled data를 seed로 하여, 그것으로부터 one-hop 떨어진 unlabeled 관계(친구, 동료 등)만을 고려
 - To bridge the labeled and unlabeled.

$$\mathcal{L}_{graph} = \sum_{u \in U} \sum_{v \in \mathcal{N}_u \cup Neg_u} -\log(\sigma(a_u^T a_v)) - Q \cdot E_{q \sim P_{neg}(u)} \log(\sigma(a_u^T a_q)),$$

$\mathbf{z}_u^T \mathbf{z}_v \approx$ probability that u and v co-occur on a random walk over the graph

- \mathcal{N}_u : user u 의 이웃
- Neg_u : user u 의 이웃 아님
- v : u 의 random walk path에서 co-occur하는 node
- Q : The number of negative samples
- a_u : generated from user's multi view information



· We utilize not only social relations of the unlabeled but also integrate their contents.

$$\mathcal{L}_{SemiGNN} = \alpha \cdot \mathcal{L}_{sup} + (1 - \alpha) \cdot \mathcal{L}_{graph} + \lambda \mathcal{L}_{reg},$$

Experiment

Dataset

Alipay에서 제공하는 Huabei라는 credit service

- 1) user-relation graph
- 2) User-app graph
- 3) User-nick graph
- 4) User-address

4m users with the known labels + Their one-hop neighbors unlabeled ≈ 100 m

Rank	User Default Prediction	User Attribute Prediction (Doctor)	
	App	Nick	Address
1	game-jjhgame (集结号捕鱼)	Head Nurse (护士长)	Maternity Hospital (妇产医院)
2	p2p-crfchina (信而富)	Dean (院长)	Pet Hospital (宠物医院)
3	p2p-iquanjin (钱站)	Clinic (诊所)	Dentistry (牙科)
4	game-templerun2 (神庙逃亡2)	Doctor (医生)	Outpatient Department (门诊部)
5	financial-eastmoney (东方财富)	Hospital of Chinese Medicine (中医院)	Clinic (诊所)
6	p2p-xiangqd (向钱贷)	Patient (病人)	Physical Examination (体检)
7	p2p-niwodai (你我贷借款)	Nurse (护士)	Stomatology Department (口腔科)
8	p2p-360jie (360借条)	Beauty (美容院)	Traditional CM Department (传统中医科)
9	shopping-aldb (魔buy商城)	Attending Doctor (主治医师)	Hospital (医院)
10	p2p-jiedaibao (借贷宝)	Dentist (牙医)	Gynecology (妇科)
11	game-lua850 (850棋牌李逵捕鱼)	Health-center (体检中心)	Rehabilitation Department (康复科)
12	entertainment-cashcomic (惠动漫)	Cosmetologist (美容师)	Nursing Department (护理部)
13	shopping-globalscanner (环球捕手)	Wardmate (病友)	Health Department (卫生部)
14	social-my (秒缘)	Radiology (放射科)	Pediatric Department (儿科)
15	p2p-daima360 (贷嘛)	Gynecology (妇科)	Obstetrics Department (产科)

Two tasks

User default prediction: 사용자가 상환을 잘 하는지 여부를 예측

User attribute prediction

Experiment


Training

Adam + lr = 0.002 + batch_size = 128 + epochs = 3

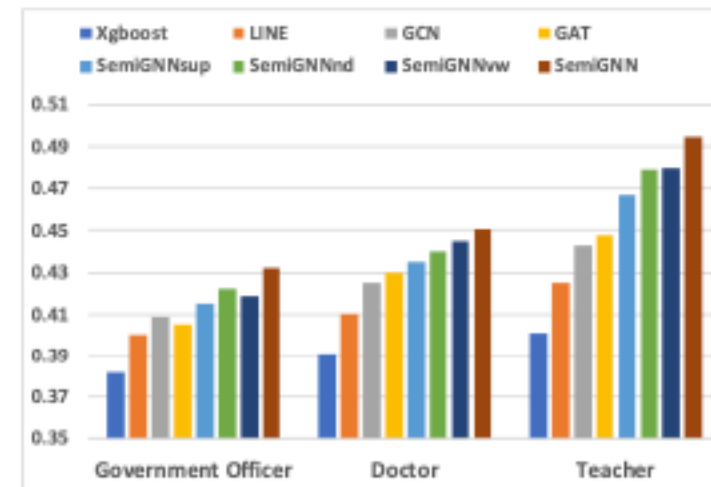
- SemiGNN_{sup} : It is a reduced version of our proposed method SemiGNN, which only utilizes the labeled data.
- SemiGNN_{nd} : It is a reduced version of SemiGNN which removes node-level attention.
- SemiGNN_{vw} : It is a reduced version of SemiGNN which removes view-level attention.

TABLE II
USER DEFAULT PREDICTION ON AUC AND KS ON ALIPAY.


Evaluation Metric	Xgboost	LINE	GCN	GAT	SemiGNN_{sup}	SemiGNN_{nd}	SemiGNN_{vw}	SemiGNN
AUC	0.753	0.771	0.780	0.784	0.786	0.798	0.801	0.807
KS	0.370	0.397	0.415	0.424	0.427	0.442	0.448	0.464



(a) F1-score




(b) Precision



(c) Recall

- $\text{SemiGNN} > \text{GCN}, \text{GAT}$
- SemiGNN_{sup} 보다 SemiGNN 의 score가 더 높다 → unlabeled data는 score 향상에 기여하는 valuable information
- KS statistic is the maximum difference between TPR and FPR



Conclusion



- Our model links the labeled and unlabeled data via their social relations
- We propose a hierarchical attention mechanism to better mine the multiview graph
 - The node-level attention is able to better correlate neighbors
 - The view-level attention can better integrate different views.
- Our method achieves better results compared with baseline methods.